

Universidad Católica de Córdoba

Facultad de Ingeniería

Ingeniería de Sistemas

ANTEPROYECTO INTEGRADOR

SONIA

Sistema de Orquestación Conversacional con Composición Dinámica de Prompts

Autores:

Agustina Perez Anziani · Mateo Josué Velásquez Borda · Tobías Valentín Nicolás

Docentes Tutores:

Ignacio Luciano Carreño · Federico Eduardo Porrini · Leandro Juarez

Córdoba, Argentina – 2026

2. Índice

2. Índice **2**
3. Resumen (Abstract) **3**
4. Palabras Clave **3**
5. Fundamentación y Planteamiento del Problema **4**
5.1. Contextualización 4
5.2. Formulación del Problema 4
5.3. Justificación 5
6. Antecedentes y Vigilancia Tecnológica **6**
6.1. Soluciones comerciales de CRM conversacional 6
6.2. Frameworks técnicos evaluados 6
6.3. Gap tecnológico identificado 6
7. Objetivos y Alcance **7**
7.1. Objetivo General 7
7.2. Objetivos Específicos (SMART) 7
7.3. Alcance 7
8. Metodología **9**
8.1. Campo de Aplicación y Tipo de Estudio 9
8.2. Población y Muestra 9
8.3. Fuentes de Información 9
8.4. Herramientas y Tecnologías 9
8.5. Arquitectura del Sistema 10
8.6. Procedimiento / Fases 10
9. Cronograma **11**
10. Bibliografía **12**
11. Anexos **13**
Anexo A – Lista Definitiva de Funcionalidades (F01–F39) 13
Anexo B – Roles y Permisos del Sistema 16
Anexo C – Modelo de Datos (esquema simplificado) 17
Anexo D – Diagrama de Gantt 18

3. Resumen (Abstract)

Español

El presente anteproyecto propone el diseño, implementación y validación de SONIA, un sistema de orquestación conversacional integrado a la API de WhatsApp Business que permite gestionar conversaciones con clientes a través de agentes de inteligencia artificial configurables. El núcleo del sistema es un motor de composición modular de prompts que ensambla dinámicamente las instrucciones del agente a partir de seis componentes persistentes (objetivo, personalidad, comportamiento, tono, voz de marca y reglas), reescribiéndolos de forma adaptativa según el historial de cada conversación.

El sistema incorpora un clasificador de transferencia que determina en qué momento el agente IA debe ceder el control al operador humano preservando el contexto completo, y un agregador inteligente con timer adaptativo que agrupa mensajes fragmentados antes de procesarlos. La plataforma provee una interfaz de bandeja operativa (inbox) con gestión de conversaciones, contactos, roles, métricas y administración de agentes, inspirada en herramientas del estado del arte en CRM conversacional.

English

This project proposes the design, implementation, and validation of SONIA, a conversational orchestration system integrated with the WhatsApp Business API that enables businesses to manage customer conversations through configurable AI agents. The core of the system is a modular prompt composition engine that dynamically assembles agent instructions from six persistent components —objective, personality, behavior, tone, brand voice, and rules— rewriting them adaptively based on each conversation's history.

The system incorporates a transfer classifier that determines when the AI agent should hand control to a human operator while preserving full conversation context, and an intelligent aggregator with an adaptive timer that groups fragmented messages before processing. The platform provides an operational inbox interface with conversation management, contact management, role-based access control, metrics, and agent administration.

4. Palabras Clave

Orquestación Conversacional · Composición Modular de Prompts · Agentes IA Configurables · Transferencia Humano-IA · WhatsApp Business API · RAG (Retrieval-Augmented Generation) · Clasificador de Transferencia · CRM Conversacional

5. Fundamentación y Planteamiento del Problema

5.1. Contextualización

El proyecto se desarrolla en el marco de la transformación digital de la gestión comercial y atención al cliente de las PYMEs de servicios en la provincia de Córdoba, Argentina, durante el período 2026-2027. La creciente adopción de WhatsApp como canal principal de comunicación entre empresas y clientes, con más del 85% de las interacciones digitales informales en Argentina realizadas por esta plataforma (Meta, 2024), ha generado una demanda sostenida de herramientas que permitan escalar la atención sin perder la calidad ni la identidad de marca.

Las soluciones actuales de CRM conversacional (Chatwoot, Respond.io, Trengo) ofrecen bandejas de mensajes y flujos automatizados, pero carecen de un mecanismo que permita configurar la identidad del agente IA de forma granular y reescribir dinámicamente sus instrucciones según el contexto de cada conversación. El resultado son agentes que responden de forma genérica, sin consistencia de tono ni capacidad de adaptarse al historial del cliente, generando una experiencia de atención inferior a la que proveería un vendedor humano bien entrenado.

5.2. Formulación del Problema

Las empresas y emprendedores que utilizan WhatsApp como canal de ventas y atención al cliente enfrentan una gran tensión estructural: necesitan atender volúmenes crecientes de consultas con equipos reducidos, sin comprometer la calidad ni la consistencia de la comunicación. La adopción de soluciones conversacionales basadas en inteligencia artificial representa una alternativa viable, pero la automatización implica mayor pérdida de identidad de marca y coherencia organizacional, y los productos actuales del mercado presentan limitaciones técnicas significativas.

Esta tensión se manifiesta en problemas concretos y documentados:

- Pérdida de consistencia de tono: los agentes actuales responden con el tono por defecto del modelo de lenguaje, sin reflejar la personalidad ni los valores del negocio.
- Falta de contexto adaptativo: el agente no incorpora información detectada en la conversación (objeciones, presupuesto, urgencia) para ajustar sus respuestas siguientes.
- Transferencia abrupta al humano: cuando el agente no puede resolver una consulta, el traspaso al operador humano se realiza sin preservar el contexto completo, obligando al cliente a repetir información.
- Ruido en la entrada: los usuarios de WhatsApp envían mensajes fragmentados en múltiples burbujas, usan abreviaturas, emojis y cambian de tema sin preaviso. Los modelos de lenguaje entrenados sobre texto formal procesan cada mensaje de forma aislada y pierden coherencia contextual.
- Ausencia de métricas de efectividad del agente: no existe una forma estándar de medir si el agente IA está siendo consistente con la identidad de marca ni cuándo y por qué falla.
- Riesgos de seguridad en datos sensibles: las conversaciones comerciales frecuentemente incluyen datos personales (DNI, CUIT, CBU, domicilio). Los sistemas actuales no ofrecen mecanismos de anonimización o filtrado previo al envío al modelo externo, exponiendo información sensible en violación a normativas de protección de datos (Ley 25.326).

Además de que los emprendedores o personas encargadas de negocios que no cuentan con vendedores sufren otro gran problema: no tienen disponibilidad 24hs para responder. Con SONIA queremos poder dar solución a esa problemática con la configuración de bots configurables por el usuario.

5.3. Justificación

¿Por qué investigar este problema? Porque la adopción masiva de WhatsApp como canal comercial ha generado una demanda insatisfecha de herramientas que combinen automatización de calidad con supervisión humana eficiente. Las soluciones existentes (chatbots estáticos, plataformas genéricas) no abordan la naturaleza fragmentada y dinámica de las conversaciones en mensajería instantánea.

¿Para qué desarrollar SONIA? Para que las PYMEs cordobesas puedan ofrecer atención automatizada con identidad de marca consistente las 24 horas, escalar su capacidad operativa sin incremento proporcional de personal, y derivar al equipo humano únicamente los casos que realmente lo requieran.

¿Qué resultados se esperan? Se proyecta una reducción del 60 % en la carga operativa del equipo de atención al cliente, una tasa de resolución autónoma superior al 75 % en consultas frecuentes, y consistencia de tono de marca medida por evaluación humana en más del 85 % de las interacciones.

Desde el punto de vista de impacto práctico, SONIA apunta a resolver un problema real y medible para el cooperante: reducir la tasa de escalada a operador humano, aumentar la consistencia de las respuestas del agente con la identidad de marca, y proveer al equipo comercial una herramienta de gestión de conversaciones que integre IA configurable con funcionalidades operativas de CRM conversacional.

6. Antecedentes y Vigilancia Tecnológica

6.1. Soluciones comerciales de CRM conversacional

Se relevaron las principales herramientas del mercado en la categoría de CRM conversacional con integración a WhatsApp:

- Chatwoot (open source): ofrece bandeja omnicanal con asignación de agentes y etiquetas, pero sin motor de composición de prompts ni agentes IA configurables por componentes.
- Chatty / Pip: herramientas inspiradoras del proyecto. Ofrecen configuración de agentes con objetivo y personalidad, pero el prompt es monolítico y no se reescribe adaptativamente según el historial.
- HubSpot / Pipedrive: CRMs completos con funcionalidades de pipeline de ventas, pero sin integración nativa con WhatsApp Business API ni agentes IA configurables para atención conversacional.
- Respond.io / Trengo: plataformas internacionales con integración de modelos de lenguaje vía API. Permiten instrucciones de sistema fijas pero carecen de mecanismos de reescritura adaptativa que contrarresten el efecto de dilución del prompt.

6.2. Frameworks técnicos evaluados

- LangChain / LlamaIndex: Frameworks Python para orquestación de LLMs con soporte RAG. Brindan bloques de construcción pero no resuelven el problema de composición modular de prompts ni la integración nativa con WhatsApp Business API.
- Botpress / Rasa: Plataformas open source para construcción de agentes conversacionales. Requieren flujos predefinidos y no contemplan la composición dinámica de personalidad en tiempo de ejecución.

6.3. Gap tecnológico identificado

Ninguna solución existente integra simultáneamente: (a) composición modular y redireccionable de prompts con seis componentes configurables por el administrador, (b) reescritura adaptativa del prompt por turno basada en información extraída de la conversación, (c) clasificador de transferencia basado en señales conversacionales múltiples, (d) agregador con timer adaptativo para mensajes fragmentados, y (e) plataforma operativa completa con gestión de contactos, roles y métricas sobre un único canal (WhatsApp). Esta brecha define el espacio de contribución original del presente proyecto.

En el ámbito académico, los trabajos de Shinn et al. (2023) sobre Reflexion y los avances en RAG multi-etapa (Lewis et al., 2020) proveen fundamento teórico para el motor de orquestación propuesto.

7. Objetivos y Alcance

7.1. Objetivo General

Diseñar, implementar y validar un sistema de orquestación conversacional que permita configurar agentes de inteligencia artificial con identidad de marca personalizada mediante composición modular de prompts, y que gestione de forma inteligente la transición entre respuesta autónoma y asistencia humana sobre el canal WhatsApp Business API, durante el período 2026–2027 en la ciudad de Córdoba, Argentina.

7.2. Objetivos Específicos (SMART)

1. **OE1.** Desarrollar el motor de composición modular de prompts (F01-F05) con seis componentes configurables por el administrador (objetivo, personalidad, comportamiento, tono, voz de marca y reglas) para el 01 de julio de 2026, logrando que el 100% de los prompts generados incorporen todos los componentes activos y que la previsualización del prompt ensamblado esté disponible en tiempo real durante la configuración [Módulo 1].
2. **OE2.** Implementar el mecanismo de reescritura adaptativa del prompt que actualice el componente de contexto dinámico en cada turno de conversación (F04), alcanzando una consistencia de tono medida por LLM-as-a-judge ≥ 80% para el 17 de agosto de 2026 [Módulo 1].
3. **OE3.** Construir el agregador de mensajes fragmentados con timer adaptativo (F10-F11) y el clasificador automático de transferencia IA → humano, logrando una precisión de clasificación de transferencia ≥ 85% sobre un conjunto de prueba de 200 conversaciones para el 28 de agosto de 2026 [Módulo 2].
4. **OE4.** Desarrollar un clasificador de estado del agente capaz de detectar señales de frustración y cambios de intención con precisión ≥ 85 % sobre un conjunto de 500 conversaciones etiquetadas, habilitando la derivación automática al operador humano, para el 07 de septiembre de 2026 [Módulo 2].
5. **OE5.** Desarrollar la plataforma operativa completa (inbox, gestión de contactos, roles, métricas) (F17-F39) con cobertura de pruebas unitarias ≥ 80% para el 23 de octubre de 2026 [Módulo 3].
6. **OE6.** Integrar el pipeline RAG sobre la base de conocimiento del cooperante (documentos de hasta 100 MB por agente), logrando que el 90% de las consultas dentro del dominio del negocio sean respondidas sin escalada al operador humano, para el 19 de marzo de 2027.
7. **OE7.** Despliegue en producción real, midiendo tasa de resolución autónoma ≥ 75% y consistencia de tono ≥ 85% en conversaciones reales.

7.3. Alcance

Incluido en el scope del proyecto

- Canal único: WhatsApp Business API.
- Módulo 1: motor de composición modular de prompts (F01–F09), incluyendo pipeline RAG, acceso a respuestas rápidas y visualización de plantillas de Meta con sugerencia de mejoras.
- Módulo 2: agregador inteligente con timer adaptativo, chunking dinámico por intenciones, clasificador de transferencia, registro de ventas y métricas de conversiones (F10–F16).
- Módulo 3: plataforma operativa completa con panel de administración, inbox en tiempo real, gestión de contactos, segmentación por etiquetas, roles diferenciados y panel de métricas gráficas (F17–F39).

- Marco legal: consentimiento explícito y almacenamiento encriptado para datos sensibles (DNI, CUIL, CBU) según Ley 25.326 de Protección de Datos Personales.
- Temporal: Mayo 2026 - Junio 2027 (13 meses). Quedan excluidos julio y diciembre del 2026, enero y febrero del 2027
- Espacial: PYMEs de servicios de la provincia de Córdoba, Argentina. La cooperante principal es la propietaria de varios departamentos en alquiler en la zona de Jesús María y Córdoba Capital, Provincia de Córdoba.

Excluido del scope (trabajo futuro)

- Canales adicionales: Instagram, canal web, email.
- Gestión de cuenta de Meta
- Creación de plantillas en Meta
- Gestión de campañas masivas de plantillas de Meta.
- Pipeline kanban de ventas con etapas y gestión de deals.
- Segmentación dinámica de contactos por comportamiento.
- Protocolo MQTT para cola de mensajes.
- Integración con Google Calendar y sheets.
- Estructura multi-empresa (multi-tenant).
- Exportación de contactos a Excel.
- Desarrollo de un LLM propio.

8. Metodología

8.1. Campo de Aplicación y Tipo de Estudio

El proyecto se enmarca en el área de ingeniería de software aplicada a sistemas conversacionales con inteligencia artificial, específicamente en el dominio de CRM conversacional sobre mensajería instantánea. Aplica al sector productivo de servicios, específicamente en el segmento PYME con atención al cliente vía mensajería instantánea. El tipo de estudio es:

- **Cuantitativo:** medición de consistencia de tono (LLM-as-judge), tasa de resolución autónoma, tasa de transferencia al humano, precisión del clasificador de transferencia y tiempo de respuesta del sistema.
- **Aplicado:** orientado a resolver un problema concreto del cooperante, con implementación en entorno real de producción durante la fase de validación.
- **Cualitativo:** análisis de conversaciones reales para identificar patrones de fragmentación, señales de frustración y casos de pérdida de identidad de marca.

8.2. Población y Muestra

La población de estudio está conformada por todas las conversaciones de clientes con el canal de WhatsApp Business del cooperante durante el período de validación. La muestra operativa consistirá en:

- 200 conversaciones para evaluación del clasificador de transferencia (OE3).

8.3. Fuentes de Información

- **Fuentes primarias:** conversaciones reales del cooperante (anonimizadas), entrevistas con el equipo comercial sobre flujos actuales de atención, y encuesta de satisfacción post-uso.
- **Fuentes secundarias:** documentación oficial de Meta (WhatsApp Business Cloud API), artículos académicos sobre composición de prompts, RAG y sistemas human-in-the-loop (arXiv, IEEE Xplore, ACL Anthology); repositorios de código abierto (GitHub), y benchmarks públicos de clasificación de intención..

8.4. Herramientas y Tecnologías

Tecnología	Módulo	Justificación técnica
Python o GO	Módulo 1 y 2	Ecosistema maduro para LLMs, embeddings (LangChain, OpenAI SDK) y ML (scikit-learn, XGBoost).
Go (Golang) o Python	Módulo 3	Goroutines para concurrencia masiva de webhooks y WebSockets sin overhead de threading.
A DEFINIR	Frontend	Interfaz operativa en tiempo real con actualización vía WebSockets para la bandeja de conversaciones.
PostgreSQL	Persistencia	Almacenamiento de contactos, conversaciones, componentes de prompts y métricas.

Tecnología	Módulo	Justificación técnica
WhatsApp Business API	Integración	Recepción y envío de mensajes vía webhooks HTTPS. Twilio Sandbox para desarrollo sin aprobación de Meta.
GPT-4o / Claude (vía API) / Cohere / Otros	IA	Modelos de lenguaje para generación de respuestas, extracción de intenciones y LLM-as-judge.
Vector Store (pgvector o Qdrant)	RAG	Búsqueda semántica sobre la base de conocimiento del negocio cooperante.
Karate Framework, SonarQube, otros.	Testing y Calidad	Es necesario testear y garantizar el Correcto funcionamiento de las funcionalidades con un Coverage del 80%

8.5. Arquitectura del Sistema

El sistema se compone de tres módulos integrados con responsabilidades claramente separadas:

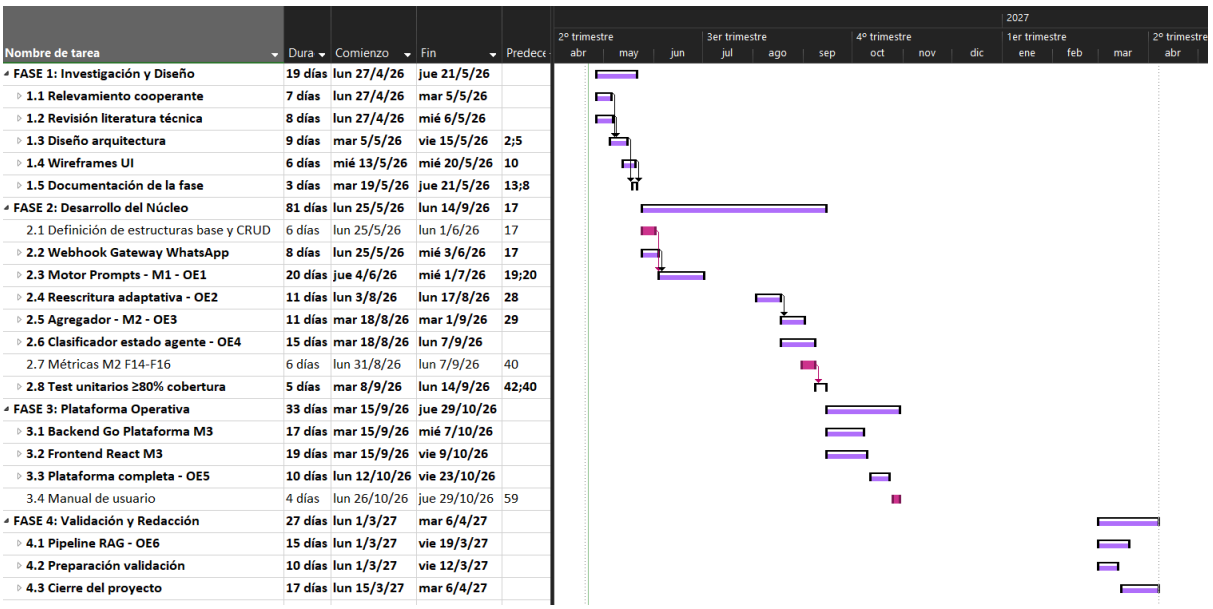
- **Gateway WhatsApp**: recibe webhooks de Meta, valida la firma HMAC-SHA256 y enruta los mensajes al agregador del Módulo 2.
- **Módulo 2 — Agregador y Clasificador**: agrupa mensajes fragmentados con timer adaptativo, detecta intenciones múltiples para chunking dinámico, transcribe audios y evalúa las señales de transferencia para decidir el estado del agente.
- **Módulo 1 — Motor de Prompts**: ensambla el prompt desde los seis componentes configurados, ejecuta la búsqueda RAG sobre la base de conocimiento, genera la respuesta vía LLM API y actualiza el contexto dinámico del agente para el siguiente turno.
- **Módulo 3 — Plataforma Operativa**: distribuye los mensajes por WebSockets a los operadores conectados, gestiona la bandeja, los contactos, los roles y el panel de métricas. Provee la interfaz de configuración de agentes al administrador.
- **Persistencia** (PostgreSQL + Vector DB): almacena todos los estados del sistema, el historial de conversaciones, los componentes de prompts, los contactos y los vectores de embeddings de la base de conocimiento.

8.6. Procedimiento / Fases

1. **Fase 1 – Investigación y Diseño**: Relevamiento detallado del cooperante. Diseño de arquitectura, modelo de datos y flujos conversacionales. Revisión de literatura sobre composición de prompts, RAG y clasificación de transferencia. Entregables: documento de arquitectura, modelo de datos, wireframes.
2. **Fase 2 – Desarrollo del Núcleo**: Implementación del motor de composición de prompts (Módulo 1), el agregador y clasificador (Módulo 2), y el gateway de WhatsApp. Integración con Twilio Sandbox para pruebas. Entregables: MVP funcional con pruebas unitarias (cobertura ≥ 80%).
3. **Fase 3 – Plataforma Operativa**: Desarrollo completo del Módulo 3 (inbox, contactos, roles, métricas). Integración end-to-end de los tres módulos. Pruebas de carga y seguridad. Entregables: sistema integrado, documentación técnica de API, manual de usuario.

4. **Fase 4 – Validación y Redacción**: Despliegue en el entorno real del cooperante con API oficial de Meta. Análisis de conversaciones. Evaluación de métricas de los OE. Redacción del informe final. Entregables: informe final, presentación, dataset del experimento.

9. Cronograma



Nombre de tarea	Dura	Comienzo	Fin	Predece
FASE 1: Investigación y Diseño	**19 días**	**lun 27/4/26**	**jue 21/5/26**	
1.1 Relevamiento cooperante	**7 días**	**lun 27/4/26**	**mar 5/5/26**	
1.2 Revisión literatura técnica	**8 días**	**lun 27/4/26**	**mié 6/5/26**	
1.3 Diseño arquitectura	**9 días**	**mar 5/5/26**	**vie 15/5/26**	**2;5**
1.4 Wireframes UI	**6 días**	**mié 13/5/26**	**mié 20/5/26**	**10**
1.5 Documentación de la fase	**3 días**	**mar 19/5/26**	**jue 21/5/26**	**13;8**
FASE 2: Desarrollo del Núcleo	**81 días**	**lun 25/5/26**	**lun 14/9/26**	**17**
2.1 Definición de estructuras base y CRUD	6 días	lun 25/5/26	lun 1/6/26	17
2.2 Webhook Gateway WhatsApp	**8 días**	**lun 25/5/26**	**mié 3/6/26**	**17**
2.3 Motor Prompts - M1 - OE1	**20 días**	**jue 4/6/26**	**mié 1/7/26**	**19;20**
2.4 Reescritura adaptativa - OE2	**11 días**	**lun 3/8/26**	**lun 17/8/26**	**28**
2.5 Agregador - M2 - OE3	**11 días**	**mar 18/8/26**	**mar 1/9/26**	**29**
2.6 Clasificador estado agente - OE4	**15 días**	**mar 18/8/26**	**lun 7/9/26**	
2.7 Métricas M2 F14-F16	6 días	lun 31/8/26	lun 7/9/26	40
2.8 Test unitarios ≥80% cobertura	**5 días**	**mar 8/9/26**	**lun 14/9/26**	**42;40**
FASE 3: Plataforma Operativa	**33 días**	**mar 15/9/26**	**jue 29/10/26**	
3.1 Backend Go Plataforma M3	**17 días**	**mar 15/9/26**	**mié 7/10/26**	
3.2 Frontend React M3	**19 días**	**mar 15/9/26**	**vie 9/10/26**	
3.3 Plataforma completa - OE5	**10 días**	**lun 12/10/26**	**vie 23/10/26**	
3.4 Manual de usuario	4 días	lun 26/10/26	jue 29/10/26	59
FASE 4: Validación y Redacción	**27 días**	**lun 1/3/27**	**mar 6/4/27**	
4.1 Pipeline RAG - OE6	**15 días**	**lun 1/3/27**	**vie 19/3/27**	
4.2 Preparación validación	**10 días**	**lun 1/3/27**	**vie 12/3/27**	
4.3 Cierre del proyecto	**17 días**	**lun 15/3/27**	**mar 6/4/27**	

Cronograma general del proyecto. 27 de abril de 2026 a 6 de abril de 2027. Duración total estimada: 7 meses activos.

Ver Anexo D para un diagrama de Gantt más detallado, o visitar el siguiente enlace de GanttPro.

10. Bibliografía

Donovan, A. A. A., & Kernighan, B. W. (2015). The Go programming language. Addison-Wesley Professional.

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. Advances in Neural Information Processing Systems, 33, 9459–9474. https://arxiv.org/abs/2005.11401

Ley Nº 25.326 de Protección de los Datos Personales (2000). Congreso de la Nación Argentina. Boletín Oficial, 30.036. https://servicios.infoleg.gob.ar/infolegInternet/anexos/60000-64999/64790/texact.htm

Meta for Developers. (2026). WhatsApp Business Platform Cloud API Reference. Meta Platforms. https://developers.facebook.com/docs/whatsapp

Ministerio de Economía Argentina. (2024). Informe sectorial: Transformación digital en PYMEs argentinas 2023–2024. Secretaría de la Pequeña y Mediana Empresa.

Shinn, N., Cassano, F., Berman, E., Gopinath, A., Narasimhan, K., & Yao, S. (2023). Reflexion: Language agents with verbal reinforcement learning. arXiv preprint arXiv:2303.11366. https://arxiv.org/abs/2303.11366

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30, 5998–6008. https://arxiv.org/abs/1706.03762

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Xia, F., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. Advances in Neural Information Processing Systems, 35, 24824–24837. https://arxiv.org/abs/2201.11903

Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., Jiang, L., Zhang, X., Zhang, S., Liu, J., Awadallah, A. H., White, R. W., Burger, D., & Wang, C. (2023). AutoGen: Enabling next-gen LLM applications via multi-agent conversation. arXiv preprint arXiv:2308.08155. https://arxiv.org/abs/2308.08155

Zheng, L., Chiang, W., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., Lin, Z., Li, Z., Li, D., Xing, E. P., Zhang, H., Gonzalez, J. E., & Stoica, I. (2023). Judging LLM-as-a-judge with MT-bench and chatbot arena. arXiv preprint arXiv:2306.05685. https://arxiv.org/abs/2306.05685

11. Anexos

Anexo A – Lista Definitiva de Funcionalidades (F01–F39)

Módulo 1 — Motor de composición y reescritura de prompts

ID	Nombre	Descripción
F01	Configuración modular del agente	Seis componentes independientes: objetivo, personalidad, comportamiento, tono, voz de marca y reglas. Incluye la configuración de cuándo delegar a un humano.
F02	Tres modos de operación	Autónomo, sugerencia (el operador revisa antes de enviar) y apagado. Configurable por conversación individual.
F03	Previsualización del prompt	El administrador ve en tiempo real el prompt ensamblado a medida que edita los componentes.
F04	Reescritura adaptativa	El motor actualiza el contexto dinámico en cada turno: inyecta objeciones, intención y datos detectados del cliente.
F05	Visualización del razonamiento	El operador ve qué componentes del prompt influyeron en cada respuesta generada.
F06	Pipeline RAG	Ingesta de documentos del negocio (límite 100 MB por agente). Búsqueda semántica para enriquecer respuestas.
F07	Acceso a respuestas rápidas	El agente IA puede usar o sugerir las respuestas rápidas precargadas por el administrador.
F08	Visualización de plantillas Meta	Muestra plantillas existentes con estado. Para las rechazadas, el LLM sugiere reformulación. No crea ni envía plantillas.
F09	Respuestas rápidas configurables	El administrador carga textos frecuentes. Los operadores los seleccionan desde el gestor de chats.

Módulo 2 — Agregador inteligente y clasificador de transferencia

ID	Nombre	Descripción
F10	Timer adaptativo	Agrupa mensajes fragmentados del usuario. El timer se reinicia con cada mensaje; procesa el bloque cuando el usuario deja de escribir.
F11	Chunking dinámico	Detecta cantidad de intenciones en el bloque y ajusta el contexto enviado al modelo para responder cada una.

ID	Nombre	Descripción
F12	Clasificador de transferencia	Detecta señales de transferencia: turnos sin resolución, frustración, consultas fuera del dominio RAG, solicitud explícita de humano
F13	Puntaje de conversaciones	El operador califica cada conversación cerrada. Alimenta métricas de efectividad.
F14	Registro de ventas	El operador marca una conversión de venta y la vincula al canal de origen y al agente que la gestionó.
F15	Trazabilidad de origen	Registra el canal de ingreso de cada contacto (Meta Ads, QR, referido, directo).
F16	Gráficas y métricas de vendedores	Panel gráfico de volumen de conversaciones en el tiempo y comparativa de rendimiento por operador. Sin gestión de campañas.

Módulo 3 — Plataforma operativa: inbox, contactos, administración y métricas

ID	Nombre	Descripción
F17	Gestión de agentes IA	Alta, baja y configuración de agentes desde el panel admin.
F18	Gestión de usuarios y roles	Roles: User (operador básico), Super Agent (puede reasignar), Admin (gestión completa).
F19	Gestión de etiquetas	El admin define el catálogo de etiquetas para segmentar conversaciones y contactos.
F20	Gestión de webhooks	Configuración de endpoints, validación de firma Meta, reintentos y log de eventos.
F21	Backend Go / WebSockets	Recibe webhooks de Meta y los distribuye en tiempo real a los operadores conectados mediante WebSockets.
F22	Vista centralizada de chats	Todos los chats con último mensaje, tiempo de espera, agente asignado y estado del bot visibles sin abrir la conversación.
F23	Filtros de bandeja	Filtros combinables: no leídas, asignadas, en espera, resueltas, por etiqueta, con recordatorio, destacadas.
F24	Etiquetas por conversación	El operador asigna etiquetas del catálogo directamente desde el chat.
F25	Destacar con estrella	Marca conversaciones para priorizar seguimientos. Son filtrables en la bandeja.

ID	Nombre	Descripción
F26	Transferencia entre operadores	Reasignación con historial completo, estado del agente IA y notas internas preservados.
F27	Control de modo por conversación	El operador cambia el modo del agente (autónomo/sugerencia/apagado) en un chat específico sin afectar los demás.
F28	Recordatorios	Alertas vinculadas a contactos con fecha. Filtrables en la bandeja y notifican al operador asignado.
F29	Restricción: sin borrado de mensajes	Limitación explícita de la API de Meta: los mensajes enviados no pueden eliminarse. Documentado en el alcance.
F30	ABM de contactos	Registro con tipos: cliente, proveedor, prospecto. Campos: nombre, apellido, teléfono, email, etiquetas, notas.
F31	Extracción automática de datos	El LLM extrae datos del usuario durante la conversación. Toggle por agente. Datos sensibles encriptados según Ley 25.326.
F32	Historial unificado por contacto	Todas las interacciones del contacto: conversaciones, operadores, calificaciones, ventas y recordatorios.
F33	Segmentación por etiquetas	Los contactos tienen etiquetas del catálogo. Filtrables en el módulo de contactos.
F34	Métricas de volumen	Conversaciones activas/resueltas/en espera, tiempos de respuesta y distribución por canal de origen.
F35	Métricas por vendedor	Conversaciones resueltas, ventas generadas, monto atribuido y tasa de conversión por operador.
F36	Métricas del agente IA	Tasa de resolución autónoma, tasa de transferencia por tipo de señal y consistencia de tono (LLM-as-judge).
F37	Panel de plantillas Meta	Visualiza estado de plantillas. Para rechazadas muestra sugerencia del LLM. Sin creación ni campañas.
F38	Gráficas temporales	Volumen de conversaciones en el tiempo, distribución horaria/semanal y evolución de métricas del agente IA.
F39	Restricción: sin campañas Meta	El sistema no gestiona envío masivo de plantillas. Trabajo futuro explícito en el documento.

Anexo B – Roles y Permisos del Sistema

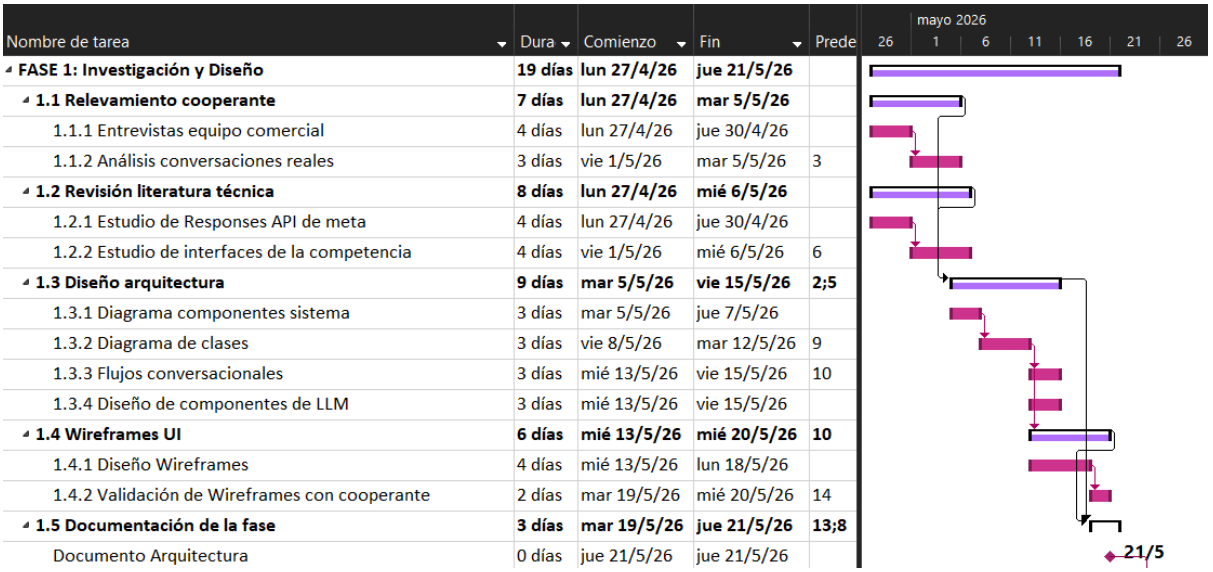
Rol	Permisos y capacidades
User (Operador básico)	Responde conversaciones asignadas. Activa o desactiva el agente IA en un chat específico. No puede reasignar ni ver conversaciones de otros operadores.
Super Agent	Todo lo de User. Además: puede reasignar conversaciones entre operadores y visualizar conversaciones de todo el equipo.
Admin	Todo lo de Super Agent. Además: gestiona agentes IA (F18), usuarios (F19), etiquetas (F20) y webhooks (F21). Accede al panel completo de métricas y configura los componentes del prompt de los agentes.

Anexo C – Modelo de Datos (esquema simplificado)

Las entidades principales del sistema y sus atributos clave son:

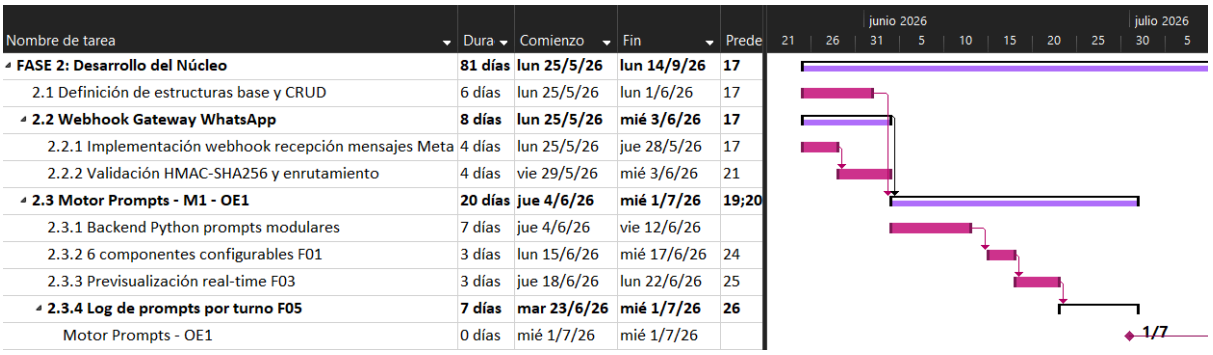
- **agents**: id, name, components_json (objetivo, personalidad, comportamiento, tono, voz_marca, reglas, umbral_transferencia), mode_default (autonomous/suggestion/off), knowledge_base_id, active.
- **conversations**: id, contact_id, agent_id, operator_id, status (active/waiting/resolved), mode (autonomous/suggestion/off), starred, score, created_at, updated_at.
- **messages**: id, conversation_id, direction (inbound/outbound), content_text, content_type (text/audio/image), transcription, prompt_snapshot_json, reasoning_json, created_at.
- **contacts**: id, phone_whatsapp (unique), name, lastname, email, type (client/provider/prospect), tags_json, notes, dni_encrypted, cuil_encrypted, cbu_encrypted, consent_given_at, created_at.
- **labels**: id, name, color, created_by_admin_id.
- **sales**: id, conversation_id, operator_id, agent_id, amount, source_channel, created_at.
- **reminders**: id, conversation_id, operator_id, description, due_at, notified, created_at.
- **knowledge_base**: id, agent_id, filename, size_bytes, embeddings_count, created_at.
- **quick_replies**: id, title, content, created_by_admin_id.

Anexo D – Diagrama de Gantt



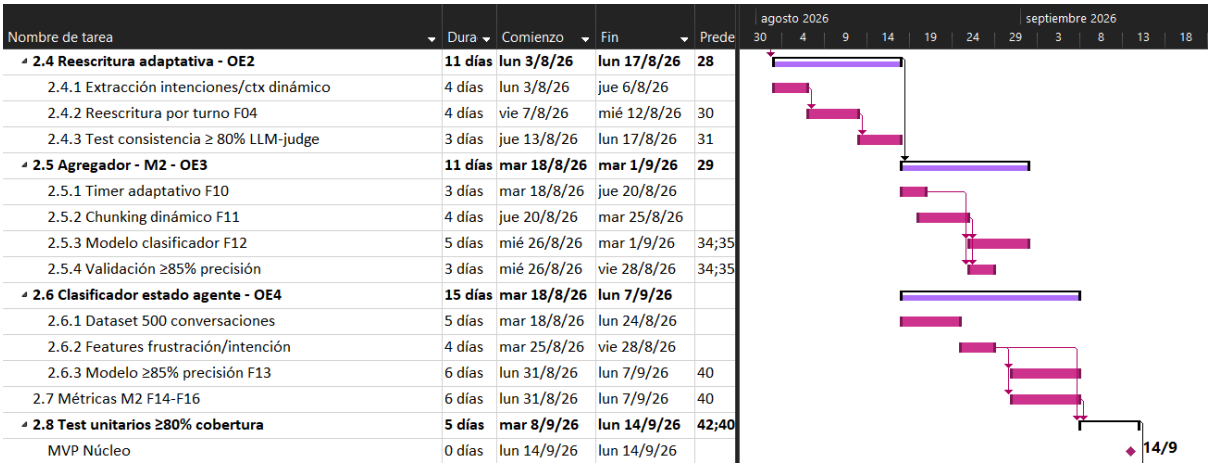
Nombre de tarea	Dura	Comienzo	Fin	Prede
FASE 1: Investigación y Diseño	**19 días**	**lun 27/4/26**	**jue 21/5/26**	
1.1 Relevamiento cooperante	**7 días**	**lun 27/4/26**	**mar 5/5/26**	
1.1.1 Entrevistas equipo comercial	4 días	lun 27/4/26	jue 30/4/26	
1.1.2 Análisis conversaciones reales	3 días	vie 1/5/26	mar 5/5/26	3
1.2 Revisión literatura técnica	**8 días**	**lun 27/4/26**	**mié 6/5/26**	
1.2.1 Estudio de Responses API de meta	4 días	lun 27/4/26	jue 30/4/26	
1.2.2 Estudio de interfaces de la competencia	4 días	vie 1/5/26	mié 6/5/26	6
1.3 Diseño arquitectura	**9 días**	**mar 5/5/26**	**vie 15/5/26**	**2;5**
1.3.1 Diagrama componentes sistema	3 días	mar 5/5/26	jue 7/5/26	
1.3.2 Diagrama de clases	3 días	vie 8/5/26	mar 12/5/26	9
1.3.3 Flujos conversacionales	3 días	mié 13/5/26	vie 15/5/26	10
1.3.4 Diseño de componentes de LLM	3 días	mié 13/5/26	vie 15/5/26	
1.4 Wireframes UI	**6 días**	**mié 13/5/26**	**mié 20/5/26**	**10**
1.4.1 Diseño Wireframes	4 días	mié 13/5/26	lun 18/5/26	
1.4.2 Validación de Wireframes con cooperante	2 días	mar 19/5/26	mié 20/5/26	14
1.5 Documentación de la fase	**3 días**	**mar 19/5/26**	**jue 21/5/26**	**13;8**
Documento Arquitectura	0 días	jue 21/5/26	jue 21/5/26	

Fase 1: Investigación y diseño. 27 de abril a 21 de mayo de 2026.



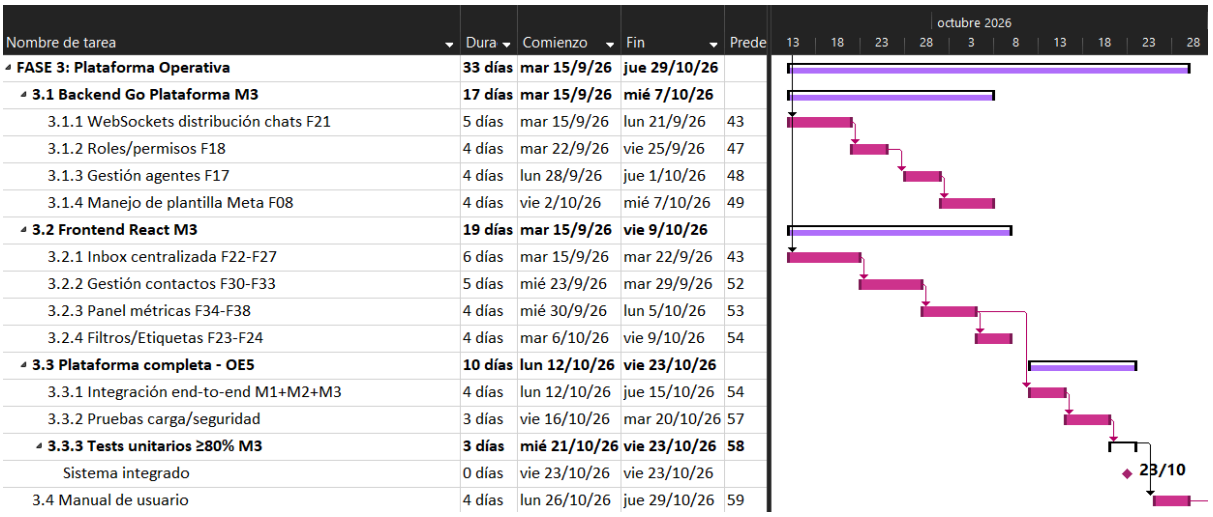
Nombre de tarea	Dura	Comienzo	Fin	Prede
FASE 2: Desarrollo del Núcleo	**81 días**	**lun 25/5/26**	**lun 14/9/26**	**17**
2.1 Definición de estructuras base y CRUD	6 días	lun 25/5/26	lun 1/6/26	17
2.2 Webhook Gateway WhatsApp	**8 días**	**lun 25/5/26**	**mié 3/6/26**	**17**
2.2.1 Implementación webhook recepción mensajes Meta	4 días	lun 25/5/26	jue 28/5/26	17
2.2.2 Validación HMAC-SHA256 y enrutamiento	4 días	vie 29/5/26	mié 3/6/26	21
2.3 Motor Prompts - M1 - OE1	**20 días**	**jue 4/6/26**	**mié 1/7/26**	**19;20**
2.3.1 Backend Python prompts modulares	7 días	jue 4/6/26	vie 12/6/26	
2.3.2 6 componentes configurables F01	3 días	lun 15/6/26	mié 17/6/26	24
2.3.3 Previsualización real-time F03	3 días	jue 18/6/26	lun 22/6/26	25
2.3.4 Log de prompts por turno F05	**7 días**	**mar 23/6/26**	**mié 1/7/26**	**26**
Motor Prompts - OE1	0 días	mié 1/7/26	mié 1/7/26	

Fase 2: Desarrollo del Núcleo, primera parte. 25 de mayo a 1 de julio de 2026.



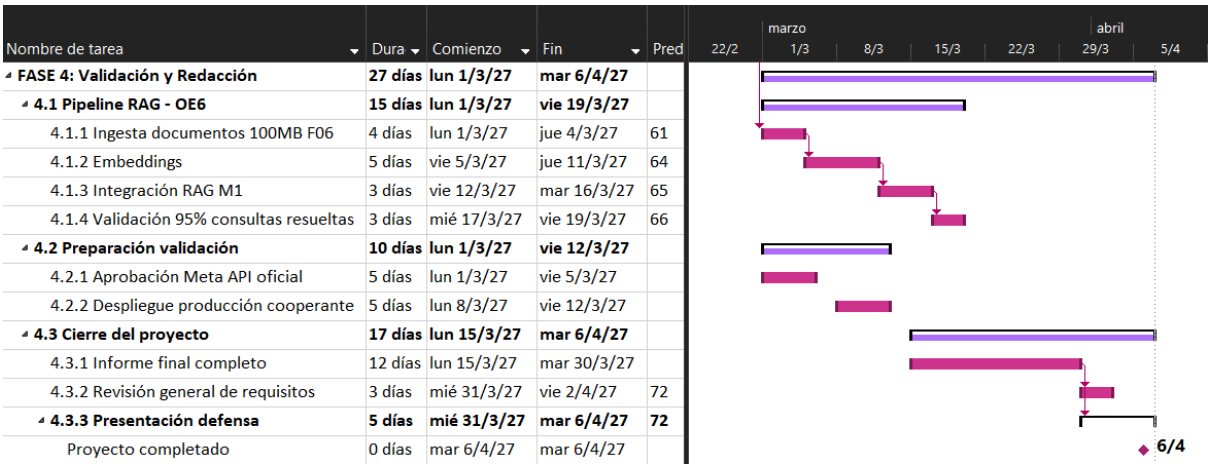
Nombre de tarea	Dura	Comienzo	Fin	Prede
2.4 Reescritura adaptativa - OE2	**11 días**	**lun 3/8/26**	**lun 17/8/26**	**28**
2.4.1 Extracción intenciones/ctx dinámico	4 días	lun 3/8/26	jue 6/8/26	
2.4.2 Reescritura por turno F04	4 días	vie 7/8/26	mié 12/8/26	30
2.4.3 Test consistencia ≥ 80% LLM-judge	3 días	jue 13/8/26	lun 17/8/26	31
2.5 Agregador - M2 - OE3	**11 días**	**mar 18/8/26**	**mar 1/9/26**	**29**
2.5.1 Timer adaptativo F10	3 días	mar 18/8/26	jue 20/8/26	
2.5.2 Chunking dinámico F11	4 días	jue 20/8/26	mar 25/8/26	
2.5.3 Modelo clasificador F12	5 días	mié 26/8/26	mar 1/9/26	34;35
2.5.4 Validación ≥85% precisión	3 días	mié 26/8/26	vie 28/8/26	34;35
2.6 Clasificador estado agente - OE4	**15 días**	**mar 18/8/26**	**lun 7/9/26**	
2.6.1 Dataset 500 conversaciones	5 días	mar 18/8/26	lun 24/8/26	
2.6.2 Features frustración/intención	4 días	mar 25/8/26	vie 28/8/26	
2.6.3 Modelo ≥85% precisión F13	6 días	lun 31/8/26	lun 7/9/26	40
2.7 Métricas M2 F14-F16	6 días	lun 31/8/26	lun 7/9/26	40
2.8 Test unitarios ≥80% cobertura	**5 días**	**mar 8/9/26**	**lun 14/9/26**	**42;40**
MVP Núcleo	0 días	lun 14/9/26	lun 14/9/26	

Fase 2: Desarrollo del Núcleo, segunda parte. 3 de agosto a 14 de septiembre de 2026.



Nombre de tarea	Dura	Comienzo	Fin	Prede
FASE 3: Plataforma Operativa	**33 días**	**mar 15/9/26**	**jue 29/10/26**	
3.1 Backend Go Plataforma M3	**17 días**	**mar 15/9/26**	**mié 7/10/26**	
3.1.1 WebSockets distribución chats F21	5 días	mar 15/9/26	lun 21/9/26	43
3.1.2 Roles/permisos F18	4 días	mar 22/9/26	vie 25/9/26	47
3.1.3 Gestión agentes F17	4 días	lun 28/9/26	jue 1/10/26	48
3.1.4 Manejo de plantilla Meta F08	4 días	vie 2/10/26	mié 7/10/26	49
3.2 Frontend React M3	**19 días**	**mar 15/9/26**	**vie 9/10/26**	
3.2.1 Inbox centralizada F22-F27	6 días	mar 15/9/26	mar 22/9/26	43
3.2.2 Gestión contactos F30-F33	5 días	mié 23/9/26	mar 29/9/26	52
3.2.3 Panel métricas F34-F38	4 días	mié 30/9/26	lun 5/10/26	53
3.2.4 Filtros/Etiquetas F23-F24	4 días	mar 6/10/26	vie 9/10/26	54
3.3 Plataforma completa - OE5	**10 días**	**lun 12/10/26**	**vie 23/10/26**	
3.3.1 Integración end-to-end M1+M2+M3	4 días	lun 12/10/26	jue 15/10/26	54
3.3.2 Pruebas carga/seguridad	3 días	vie 16/10/26	mar 20/10/26	57
3.3.3 Tests unitarios ≥80% M3	**3 días**	**mié 21/10/26**	**vie 23/10/26**	**58**
Sistema integrado	0 días	vie 23/10/26	vie 23/10/26	
3.4 Manual de usuario	4 días	lun 26/10/26	jue 29/10/26	59

Fase 3: Plataforma Operativa. 15 de septiembre a 29 de octubre de 2026.



Nombre de tarea	Dura	Comienzo	Fin	Pred
FASE 4: Validación y Redacción	**27 días**	**lun 1/3/27**	**mar 6/4/27**	
4.1 Pipeline RAG - OE6	**15 días**	**lun 1/3/27**	**vie 19/3/27**	
4.1.1 Ingesta documentos 100MB F06	4 días	lun 1/3/27	jue 4/3/27	61
4.1.2 Embeddings	5 días	vie 5/3/27	jue 11/3/27	64
4.1.3 Integración RAG M1	3 días	vie 12/3/27	mar 16/3/27	65
4.1.4 Validación 95% consultas resueltas	3 días	mié 17/3/27	vie 19/3/27	66
4.2 Preparación validación	**10 días**	**lun 1/3/27**	**vie 12/3/27**	
4.2.1 Aprobación Meta API oficial	5 días	lun 1/3/27	vie 5/3/27	
4.2.2 Despliegue producción cooperante	5 días	lun 8/3/27	vie 12/3/27	
4.3 Cierre del proyecto	**17 días**	**lun 15/3/27**	**mar 6/4/27**	
4.3.1 Informe final completo	12 días	lun 15/3/27	mar 30/3/27	
4.3.2 Revisión general de requisitos	3 días	mié 31/3/27	vie 2/4/27	72
4.3.3 Presentación defensa	**5 días**	**mié 31/3/27**	**mar 6/4/27**	**72**
Proyecto completado	0 días	mar 6/4/27	mar 6/4/27	

Fase 4: Validación y Redacción. 1 de marzo a 6 de abril de 2027.